

Aprendizaje automático orientado a la clasificación de cáncer de piel: un enfoque basado en EfficientNetB1

Deborah Famadas Rodríguez

Tutores:

Dr. Reinaldo Rodríguez Ramos*

Dr. Yudivian Almeida Cruz

January 16, 2024

Universidad de la Habana (UH)

*Universidade Federal Fluminense (UFF), Rio de Janeiro, Brasil

github.com/deborahfam/Thesis



Cáncer de piel



MACHINE LEARNING



Minería de
datos



Algoritmos



Clasificación



Aprendizaje



Redes
neuronales



Aprendizaje
profundo



IA



Autonomía



Propósito central

Desarrollar un modelo de *deep learning* para el diagnóstico de cáncer de piel a través de la clasificación de imágenes dermatológicas.

Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Optimización de la distribución de datos.
4. Mejoras y ajuste de hiperparámetros.
5. Implementación de técnicas de validación.



Propósito central

Desarrollar un modelo de *deep learning* para el diagnóstico de cáncer de piel a través de la clasificación de imágenes dermatológicas.

Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Optimización de la distribución de datos.
4. Mejoras y ajuste de hiperparámetros.
5. Implementación de técnicas de validación.



Objetivos

Propósito central

Desarrollar un modelo de *deep learning* para el diagnóstico de cáncer de piel a través de la clasificación de imágenes dermatológicas.

Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Optimización de la distribución de datos.
4. Mejoras y ajuste de hiperparámetros.
5. Implementación de técnicas de validación.



Propósito central

Desarrollar un modelo de *deep learning* para el diagnóstico de cáncer de piel a través de la clasificación de imágenes dermatológicas.

Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Optimización de la distribución de datos.
4. Mejoras y ajuste de hiperparámetros.
5. Implementación de técnicas de validación.



Propósito central

Desarrollar un modelo de *deep learning* para el diagnóstico de cáncer de piel a través de la clasificación de imágenes dermatológicas.

Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Optimización de la distribución de datos.
4. Mejoras y ajuste de hiperparámetros.
5. Implementación de técnicas de validación.



Propósito central

Desarrollar un modelo de *deep learning* para el diagnóstico de cáncer de piel a través de la clasificación de imágenes dermatológicas.

Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Optimización de la distribución de datos.
4. Mejoras y ajuste de hiperparámetros.
5. Implementación de técnicas de validación.



Propósito central

Desarrollar un modelo de *deep learning* para el diagnóstico de cáncer de piel a través de la clasificación de imágenes dermatológicas.

Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Optimización de la distribución de datos.
4. Mejoras y ajuste de hiperparámetros.
5. Implementación de técnicas de validación.



¿Qué son las CNNs?

Componentes de la arquitectura de las CNNs




Figure 1: Estructura de una red neuronal convolucional.



¿Qué son las CNNs?

Componentes de la arquitectura de las CNNs




Figure 1: Estructura de una red neuronal convolucional.



¿Qué son las CNNs?

Componentes de la arquitectura de las CNNs




Figure 1: Estructura de una red neuronal convolucional.



Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Optimización de la distribución de datos.
4. Mejoras y ajuste de hiperparámetros.
5. Implementación de técnicas de validación.



Red neuronales pre-entrenadas

1. Generales o profundas
2. De varias capas (*multilayers*).
3. Completamente conectadas (*fully connected*).

Transferencia de aprendizaje (transfer learning)




Figure 2: Algoritmos de transferencia de aprendizaje.



Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Mejoras y ajuste de hiperparámetros.
4. Optimización de la distribución de datos.
5. Implementación de técnicas de validación.



- Una red neuronal convolucional propia que utiliza como entrada los pesos obtenidos de una red neuronal convolucional pre-entrenada, EfficientNetB1.
- Algoritmo propio para ajuste de precisión.



- Una red neuronal convolucional propia que utiliza como entrada los pesos obtenidos de una red neuronal convolucional pre-entrenada, EfficientNetB1.
- Algoritmo propio para ajuste de precisión.






Figure 3: Desempeño de los modelos de EfficientNet.



- Una red neuronal convolucional propia que utiliza como entrada los pesos obtenidos de una red neuronal convolucional pre-entrenada, EfficientNetB1.
- Algoritmo propio para ajuste de precisión.



Modelo y capas adicionales

- Capa de normalización.
- Capa densa y regularización.
- Capa de *dropout*.
- Capa de salida con activación *softmax*.



Figure 4: Diagrama del modelo propuesto.

Tasa de Aprendizaje Inicial: 0.001,

Regularización: L2 con $\lambda = 0.016$ y L1 con $\lambda = 0.006$,

Dropout: 45%,

Dimensiones de la Imagen: $224 \times 224 \times 3$,

Optimizador: Adamax



- Una red neuronal convolucional propia que utiliza como entrada los pesos obtenidos de una red neuronal convolucional pre-entrenada, EfficientNetB1.
- Algoritmo propio para ajuste de precisión.



Ajuste de tasa de aprendizaje

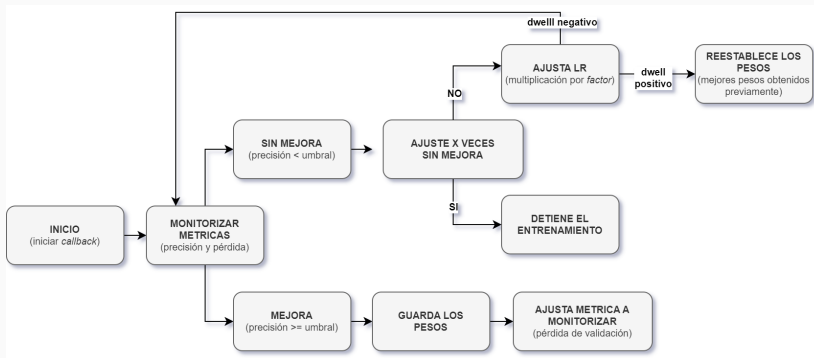


Figure 5: Diagrama del algoritmo de ajuste de aprendizaje.

Epochs: 40, **Patience:** 1, **Stop Patience:** 3, **Threshold:** 0.9,
Factor: 0.5



Propósitos específicos

1. Estudio del estado del arte en diagnóstico de imágenes dermatológicas.
2. Desarrollo de un modelo de *deep learning* para clasificación.
3. Mejoras y ajuste de hiperparámetros.
4. Optimización de la distribución de datos.
5. Implementación de técnicas de validación.



Fuente de Datos: HAM10000

- Conjunto de datos con 10015 imágenes dermatoscópicas.
- Amplia gama de lesiones cutáneas pigmentadas.

Categoría Diagnóstica	Cantidad	Porcentaje
Melanocytic nevi (NV)	6705	66.95%
Melanoma (MEL)	1113	11.11%
Benign keratosis-like lesions (BKL)	1099	10.97%
Basal cell carcinoma (BCC)	514	5.13%
Actinic Keratosis and Intraepithelial Carcinoma (AKIEC)	327	3.27%
Vascular lesions (VASC)	142	1.42%
Dermatofibroma (DF)	115	1.15%

Table 1: Distribución de imágenes por categoría diagnóstica.



Transformación de Datos

- Transformación de formato **one hot encoding** a formato categórico **categorical**.

Image	MEL	NV	BCC	AKIEC	BKL	DF	VASC
ISIC_0024306	0	1	0	0	0	0	0
ISIC_0024307	0	1	0	0	0	0	0
ISIC_0024308	0	1	0	0	0	0	0
ISIC_0024309	0	1	0	0	0	0	0
ISIC_0024310	1	0	0	0	0	0	0



Image	Etiqueta
ISIC_0024306.jpg	NV
ISIC_0024307.jpg	NV
ISIC_0024308.jpg	NV
ISIC_0024309.jpg	NV
ISIC_0024310.jpg	MEL

- División en entrenamiento, validación y prueba.
- Aumento de datos (*data augmentation*).
 - Rango de rotación
 - Rango de desplazamiento horizontal y vertical
 - Rango de corte y zoom
 - Volteo horizontal
 - Relleno para manejar los píxeles faltantes



Transformación de Datos

- Transformación de formato **one hot encoding** a formato categórico **categorical**.

Image	MEL	NV	BCC	AKIEC	BKL	DF	VASC
ISIC_0024306	0	1	0	0	0	0	0
ISIC_0024307	0	1	0	0	0	0	0
ISIC_0024308	0	1	0	0	0	0	0
ISIC_0024309	0	1	0	0	0	0	0
ISIC_0024310	1	0	0	0	0	0	0



Image	Etiqueta
ISIC_0024306.jpg	NV
ISIC_0024307.jpg	NV
ISIC_0024308.jpg	NV
ISIC_0024309.jpg	NV
ISIC_0024310.jpg	MEL

- División en entrenamiento, validación y prueba.
- Aumento de datos (*data augmentation*).
 - Rango de rotación
 - Rango de desplazamiento horizontal y vertical
 - Rango de corte y zoom
 - Volteo horizontal
 - Relleno para manejar los píxeles faltantes



Transformación de Datos

- Transformación de formato **one hot encoding** a formato categórico **categorical**.

Image	MEL	NV	BCC	AKIEC	BKL	DF	VASC
ISIC_0024306	0	1	0	0	0	0	0
ISIC_0024307	0	1	0	0	0	0	0
ISIC_0024308	0	1	0	0	0	0	0
ISIC_0024309	0	1	0	0	0	0	0
ISIC_0024310	1	0	0	0	0	0	0



Image	Etiqueta
ISIC_0024306.jpg	NV
ISIC_0024307.jpg	NV
ISIC_0024308.jpg	NV
ISIC_0024309.jpg	NV
ISIC_0024310.jpg	MEL

- División en entrenamiento, validación y prueba.
- Aumento de datos (*data augmentation*).
 - Rango de rotación
 - Rango de desplazamiento horizontal y vertical
 - Rango de corte y zoom
 - Volteo horizontal
 - Relleno para manejar los píxeles faltantes



- Experimento 1: División asimétrica de datos.
- Experimento 2: Estratificación equilibrada de datos.



Experimentos 1: División asimétrica de datos

- División en entrenamiento, validación y prueba.

Categoría diagnóstica	Porcentaje	Cantidad de datos
Entrenamiento	95%	9514
Validación	2.5%	251
Prueba	2.5%	251

- Establecer la cantidad fija de muestras por clase (300).
- Aplicar **class weighting**.



Experimentos 1: División asimétrica de datos

- División en entrenamiento, validación y prueba.

Categoría diagnóstica	Porcentaje	Cantidad de datos
Entrenamiento	95%	9514
Validación	2.5%	251
Prueba	2.5%	251

- Establecer la cantidad fija de muestras por clase (300).
- Aplicar **class weighting**.



Experimentos 1: División asimétrica de datos

- División en entrenamiento, validación y prueba.

Categoría diagnóstica	Porcentaje	Cantidad de datos
Entrenamiento	95%	9514
Validación	2.5%	251
Prueba	2.5%	251

- Establecer la cantidad fija de muestras por clase (300).
- Aplicar **class weighting**.

Categoría diagnóstica	Muestras	Pesos
AKIEC	300	1.00
BCC	300	1.00
BKL	300	1.00
DF	107	2.60
MEL	300	1.00
NV	300	1.00
VASC	138	2.11



Resultados del experimento 1

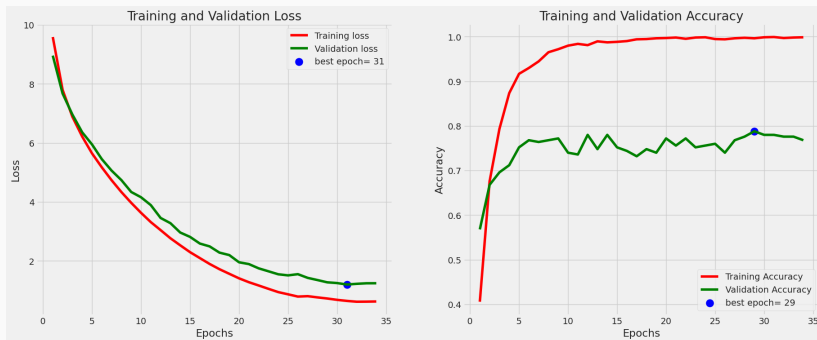


Figure 6: Curva de aprendizaje a lo largo del proceso de entrenamiento del experimento 1.



Resultados del experimento 1

		Confusion Matrix						
Actual	AKIEC	7	0	0	0	0	0	0
	BCC	0	10	0	0	0	0	0
	BKL	2	2	19	0	5	1	1
	DF	0	0	0	3	0	0	0
	MEL	2	3	1	0	28	1	0
	NV	4	2	9	6	7	134	1
	VASC	0	0	0	0	0	0	3
		AKIEC	BCC	BKL	DF	MEL	NV	VASC
		Predicted						



Figure 7: Matriz de confusión del experimento 1.

Experimentos 2: Estratificación equilibrada de datos

- División en entrenamiento, validación y prueba.

Categoría diagnóstica	Porcentaje	Cantidad de datos
Entrenamiento	70%	7010
Validación	15%	1502
Prueba	15%	1503

- Establecer la cantidad fija de muestras por clase (500).



Experimentos 2: Estratificación equilibrada de datos

- División en entrenamiento, validación y prueba.

Categoría diagnóstica	Porcentaje	Cantidad de datos
Entrenamiento	70%	7010
Validación	15%	1502
Prueba	15%	1503

- Establecer la cantidad fija de muestras por clase (500).

Categoría diagnóstica	Entrenamiento	Validación	Prueba
NV	500	1006	1006
MEL	500	167	167
BKL	500	165	165
DF	500	17	17
AKIEC	500	49	49
BCC	500	77	77
VASC	500	21	22



Resultados del experimento 2



Figure 8: Curva de aprendizaje a lo largo del proceso de entrenamiento del experimento 2.



Resultados del experimento 2

		Confusion Matrix						
Actual	AKIEC	47	1	0	0	1	0	0
	BCC	0	77	0	0	0	0	0
	BKL	6	2	137	1	12	7	0
	DF	0	0	0	17	0	0	0
	MEL	2	0	8	1	142	14	0
	NV	2	15	44	5	69	862	9
	VASC	0	0	0	0	0	0	22
		AKIEC	BCC	BKL	DF	MEL	NV	VASC
		Predicted						



Figure 9: Matriz de confusión del experimento 2.

Table 2: Informe de clasificación combinado para los experimentos 1 y 2.

Categoría	Experimento 1					Experimento 2				
	Acc	Recall	F1	F2	NM	Acc	Recall	F1	F2	NM
AKIEC	0.47	1.00	0.64	0.816	7	0.82	0.96	0.89	0.928	49
BCC	0.59	1.00	0.74	0.878	10	0.81	1.00	0.90	0.955	77
BKL	0.66	0.63	0.64	0.636	30	0.72	0.83	0.77	0.805	165
DF	0.33	1.00	0.50	0.711	3	0.71	1.00	0.83	0.924	17
MEL	0.70	0.80	0.75	0.778	35	0.63	0.85	0.73	0.795	167
NV	0.99	0.82	0.90	0.849	163	0.98	0.86	0.91	0.882	1006
VASC	0.60	1.00	0.75	0.882	3	0.71	1.00	0.83	0.924	22
Acc			0.81		251			0.87		1503
MacroAvg	0.62	0.89	0.70		251	0.77	0.93	0.84		1503



Conclusiones

- **Potencial del aprendizaje profundo:** Alta precisión y eficiencia en diagnóstico de cáncer de piel.
- **Eficacia de la clasificación:** 87% de eficacia, comparable con los métodos del estado del arte.
- **Comparación entre experimentos:** Mejoras significativas en precisión, recall y puntuaciones F1.
- **Análisis de curvas de aprendizaje:** Convergencia más rápida y mejor generalización en el segundo experimento.
- **Estadísticas de eficacia y matrices de confusión:** Clasificación precisa en varias clases de cáncer de piel.
- **Importancia del conjunto de datos:** Calidad y composición del conjunto de datos HAM10000 como aspectos críticos.



1. Enriquecimiento de datos: Añadir más imágenes para robustecer el modelo.
2. Aumentar la diversidad de datos: Aplicar técnicas de aumento de datos.
3. Balance de clases mediante aumento: Equilibrar la distribución de clases y distribución representativa en todas las particiones.



1. Regularización y arquitectura de red: Explorar parámetros de regularización.
2. Precisión y sesgos: Mejorar clasificación en clases menos representadas.
3. Optimizadores: Probar con RMSprop o SGD para mejorar rendimiento.



¡Gracias por su atención!



Preguntas del OPONENTE

1. ¿Por qué si EfficientNetB4 tiene mejor precisión se utilizó EfficientNetB1?
2. ¿En qué se basaron los parámetros seleccionados de regularización y de la estrategia de cambio de tasa de aprendizaje?
3. Para las clases con menos elementos (Tabla 3.5 manuscrito) hay clases como la DF que solo tienen 115 elementos, se puede observar según la tabla que estos casos se utilizaron todos los elementos para el entrenamiento y a su vez algunos para validación. Explique en más detalle este proceder y en caso de ser así, explique brevemente que efecto puede tener esto sobre los resultados de precisión?
4. Cree que con preprocesamiento más robusto (mejor nitidez, contraste, etc) o con un aumento de parámetros del modelo se puedan mejorar los resultados?



Preguntas del OPONENTE

1. ¿Por qué si EfficientNetB4 tiene mejor precisión se utilizó EfficientNetB1?
2. ¿En qué se basaron los parámetros seleccionados de regularización y de la estrategia de cambio de tasa de aprendizaje?
3. Para las clases con menos elementos (Tabla 3.5 manuscrito) hay clases como la DF que solo tienen 115 elementos, se puede observar según la tabla que estos casos se utilizaron todos los elementos para el entrenamiento y a su vez algunos para validación. Explique en más detalle este proceder y en caso de ser así, explique brevemente que efecto puede tener esto sobre los resultados de precisión?
4. Cree que con preprocesamiento más robusto (mejor nitidez, contraste, etc) o con un aumento de parámetros del modelo se puedan mejorar los resultados?



Pregunta 2

Regularización

- L2 con $\lambda = 0.016$.
 - Valores entre 0.01 y 0.1.
 - Simplicidad del modelo
- L1 con $\lambda = 0.006$.
 - Selección de características.

Ajuste de tasa de aprendizaje

- Se prioriza precisión (*accuracy*) y a partir de un umbral se empieza a priorizar pérdida de validación.
- Enfoque de multi-clasificación.



Preguntas del OPONENTE

1. ¿Por qué si EfficientNetB4 tiene mejor precisión se utilizó EfficientNetB1?
2. ¿En qué se basaron los parámetros seleccionados de regularización y de la estrategia de cambio de tasa de aprendizaje?
3. Para las clases con menos elementos (Tabla 3.5 manuscrito) hay clases como la DF que solo tienen 115 elementos, se puede observar según la tabla que estos casos se utilizaron todos los elementos para el entrenamiento y a su vez algunos para validación. Explique en más detalle este proceder y en caso de ser así, explique brevemente que efecto puede tener esto sobre los resultados de precisión?
4. Cree que con preprocesamiento más robusto (mejor nitidez, contraste, etc) o con un aumento de parámetros del modelo sepuedan mejorar los resultados?



Pregunta 3

Categoría diagnóstica	Entrenamiento	Validación	Prueba
NV	300	158	163
MEL	300	25	35
BKL	300	34	30
DF	107	5	3
AKIEC	300	11	7
BCC	300	16	10
VASC	138	1	3

Table 3: Distribución de imágenes de cáncer de piel en los conjuntos de entrenamiento, prueba y validación.



Preguntas del OPONENTE

1. ¿Por qué si EfficientNetB4 tiene mejor precisión se utilizó EfficientNetB1?
2. ¿En qué se basaron los parámetros seleccionados de regularización y de la estrategia de cambio de tasa de aprendizaje?
3. Para las clases con menos elementos (Tabla 3.5 manuscrito) hay clases como la DF que solo tienen 115 elementos, se puede observar según la tabla que estos casos se utilizaron todos los elementos para el entrenamiento y a su vez algunos para validación. Explique en más detalle este proceder y en caso de ser así, explique brevemente que efecto puede tener esto sobre los resultados de precisión?
4. Cree que con preprocesamiento más robusto (mejor nitidez, contraste, etc) o con un aumento de parámetros del modelo se puedan mejorar los resultados?



¡Gracias por su atención!
Nuevamente

