

Universidad de La Habana  
Facultad de Matemática y Computación



## Título de la tesis

Autor:

**Deborah Famadas Rodríguez**

Tutores:

**Dr. Reinaldo Rodríguez Ramos, Universidad de la  
Habana**

**Dr. Yudivian Almeida, Universidad de la Habana**

Trabajo de Diploma  
presentado en opción al título de  
Licenciado en Ciencia de la Computación

Fecha

[github.com/deborahfam/Thesis](https://github.com/deborahfam/Thesis)

Dedicación

# Agradecimientos

Agradecimientos

# Opinión del tutor

Opiniones de los tutores

# Resumen

Resumen en español

# Abstract

Resumen en inglés

# Índice general

<b>Introducción</b>	<b>1</b>
<b>1. Estado del Arte</b>	<b>2</b>
<b>2. Propuesta</b>	<b>3</b>
2.1. Metodología . . . . .	3
2.2. Preparación y Carga de Datos . . . . .	3
2.2.1. Transformación de Datos . . . . .	3
2.2.2. Modelación y división del conjunto de datos . . . . .	4
2.3. Generadores de Datos y Preprocesamiento . . . . .	4
2.4. Diseño y Entrenamiento del Modelo . . . . .	5
2.4.1. Capas Adicionales y Regularización . . . . .	5
2.4.2. Optimización . . . . .	6
2.4.3. Ajuste Dinámico de la Tasa de Aprendizaje . . . . .	6
<b>3. Detalles de Implementación y Experimentos</b>	<b>7</b>
<b>Conclusiones</b>	<b>8</b>
<b>Recomendaciones</b>	<b>9</b>
<b>Bibliografía</b>	<b>10</b>

# Índice de figuras



## Ejemplos de código

# Introducción

# Capítulo 1

## Estado del Arte

El cáncer de piel es el más frecuente del mundo *annadir cita* . A diferencia de muchos otros tipos de cáncer que se desarrollan internamente, el cáncer de piel se forma externamente y suele ser visible, lo que lo convierte en el "cáncer que se ve". Esta visibilidad subraya la importancia de los exámenes de la piel, tanto realizados por uno mismo como por dermatólogos. El diagnóstico y el tratamiento oportunos son primordiales. La mayoría de los casos de cáncer de piel son tratables si se detectan precozmente, lo que subraya la necesidad de identificar la enfermedad con prontitud. La detección precoz no sólo salva vidas, sino que también evita que la enfermedad se vuelva peligrosa, desfigurante o incluso mortal.

# Capítulo 2

## Propuesta

### 2.1. Metodología

En este capítulo se propone una método para la detección de cáncer de piel mediante el aprendizaje automático. Este enfoque de solución se basa en la implementación de una red neuronal profunda para analizar y categorizar automáticamente imágenes, con el objetivo de asistir en la detección de posibles casos malignos y mejorar la eficiencia del proceso diagnóstico.

A continuación, se introducen algunos de los conceptos básicos de los métodos o técnicas que se emplearan a lo largo del capítulo.

### 2.2. Preparación y Carga de Datos

Los datos utilizados como medio de aprendizaje para este proyecto son: Imágenes y Metadatos. Los datos son extraídos del Dataset: HAM1000-segmentation-and-classification *Conjunto de datos HAM10000* 2023. El mismo contiene imágenes tomadas de varios tipos de cáncer de piel y contiene además un archivo Excel formato csv de Metadatos. Los metadatos contienen información relacionada con cada imagen con un formato de *one hot encoding*.

#### 2.2.1. Transformación de Datos

Para optimizar la eficiencia del algoritmo, se procesan las imágenes realizando diversas modificaciones, que incluyen: eliminación de cabello, luces y sombras, división de canales y aplicación de un leve desenfoque.

Los metadatos, asociados a la clasificación, están etiquetados utilizando el método de *one hot encoding*. Fue necesario convertirlos a un formato *categorico* para su

procesamiento..

El *one hot encoding* es una técnica de procesamiento de datos en la cual cada valor categórico se representa mediante un vector binario cuyo tamaño corresponde al número de categorías posibles. En dicho vector, todos los elementos son cero, salvo el correspondiente a la categoría del valor, que es uno *One-hot encoding* 2023.

Se define *categórico* como el formato en el que a cada elemento se le asigna el nombre de una categoría como propiedad.

### 2.2.2. Modelación y división del conjunto de datos

Los datos se modelan a partir de un Dataframe de Pandas *Dataframes de Pandas* 2023. Los mismo son divididos luego en 3 conjuntos: Entrenamiento, Validación y Prueba. Estas divisiones son necesarias para que el modelo pueda aprender y ser evaluado correctamente.

Aquí, se define que el 95% de los datos se utilizará para entrenamiento y la cantidad restante se considera en un conjunto dummy, el cual luego es dividido en validación y prueba. En esta última división al conjunto de validación le corresponde una cantidad del 50% del conjunto dummy (lo que es equivalente al 2.5% del df original) y el conjunto de prueba el 50% restante (también equivalente al 2.5% del df original). Además se mezclan aleatoriamente los datos y se utiliza una variable fija para garantizar que la división sea reproducible.

En el contexto del Machine Learning (Aprendizaje de Máquinas), un DataFrame de Pandas es una estructura de datos bidimensional, similar a una tabla, proporcionada por la biblioteca Python *Pandas*. Facilita la manipulación y análisis de grandes conjuntos de datos, permitiendo una organización clara en forma de filas y columnas.

## 2.3. Generadores de Datos y Preprocesamiento

Se detectó que el conjunto de datos estaba altamente desequilibrado. Por lo tanto, limitamos el número máximo de muestras por clase a 300 para equilibrar el conjunto de datos.

Se empleó *ImageDataGenerator* *ImageDataGenerator* 2023 para cargar, transformar y generar lotes de imágenes durante el entrenamiento. El *ImageDataGenerator* es una herramienta ofrecida por la biblioteca *Keras*, diseñada específicamente para el procesamiento y manejo de imágenes en tareas de Machine Learning. Se inicializa con varias transformaciones (como rotación, desplazamiento y zoom) para aplicar automáticamente estas transformaciones a las imágenes a medida que se cargan devolver lotes de imágenes listos para el entrenamiento o la evaluación del modelo, lo cual permite alimentar la red neuronal de manera eficiente *Aumentación de datos* 2023 .

Además, implementamos *Class Weighting*. Este método se refiere a la asignación de pesos diferenciados a cada clase durante el proceso de entrenamiento del modelo debido conjuntos de datos desequilibrados, con el objetivo de reforzar la señal de entrenamiento de las clases menos representadas, o sea, las clases/categorías con menos cantidad de datos.

## 2.4. Diseño y Entrenamiento del Modelo

Se utiliza la arquitectura de red neural denominada *EfficientNetB1* *EfficientNetB1* s.f. . Esta arquitectura forma parte de la familia EfficientNet, que está diseñada para proporcionar alta precisión mientras se mantiene un tamaño de modelo y una complejidad computacional eficientes.

Para aprovechar los conocimientos previos y acelerar el entrenamiento, se carga el modelo *EfficientNetB1* pre-entrenado con los pesos obtenidos de entrenar en el dataset *ImageNet*, que es una amplia base de datos de imágenes utilizada comúnmente para entrenamiento y *benchmarking* en tareas de visión por computadora. Utilizar un modelo pre-entrenado permite aprovechar las características que ya ha aprendido de este amplio conjunto de datos, facilitando su adaptación al dataset.

Se utiliza el *EfficientNetB1* sin incluir su capa superior, con el objetivo de añadir y personalizar capas adicionales. Tras obtener la salida del modelo base, se aplica una serie de transformaciones, incluyendo normalización por lotes, una capa densa con regularizaciones, una técnica de *Dropout* para prevenir el sobre-ajuste y una capa de optimización.

### 2.4.1. Capas Adicionales y Regularización

Aunque el modelo EfficientNetB1 es poderoso por sí solo, no está perfectamente adaptado a nuestro problema específico. Para ajustarlo a nuestras necesidades, se añaden capas adicionales:

1. Normalización por Lotes: Esta capa busca estandarizar las activaciones del modelo para cada lote de entrenamiento. La misma regulariza el modelo y, al mismo tiempo, suele acelerar el entrenamiento ya que permite utilizar tasas de aprendizaje más altas. [*Regularización* 2023]
2. Densa: Se introduce una capa completamente conectada con 256 neuronas. Esta capa tiene una activación ReLU y utiliza regularización L1 y L2. La regularización L1 y L2 penaliza los pesos grandes en la red, ayudando a evitar el sobre-ajuste y garantizando que el modelo se generalice bien a nuevos datos. [*Capas densas* 2023]

3. Dropout: Esta técnica de regularización desactiva aleatoriamente una fracción (en este caso, el 45 %) de las neuronas durante el entrenamiento. Esta aleatoriedad ayuda a evitar la dependencia excesiva en cualquier neurona individual, lo que a su vez ayuda a prevenir el sobre-ajuste. *Dropout* 2023
4. Capa de Salida: Finalmente, se agrega una capa densa que tiene un número de neuronas igual al número de clases en nuestro problema. La activación *softmax* se utiliza aquí para transformar las salidas en probabilidades de clase.

### 2.4.2. Optimización

Para el proceso de entrenamiento, se utiliza el optimizador *Adamax* *Adamax* 2023. Este es una variante del conocido optimizador Adam, que combina las ventajas de los métodos adaptativos de tasa de aprendizaje con una implementación más robusta en presencia de momentos espurios.

Se configura el modelo para minimizar la categorical crossentropy, que es una medida común de error para problemas de clasificación, y se rastrea la precisión como métrica principal.

### 2.4.3. Ajuste Dinámico de la Tasa de Aprendizaje

Una de las características más innovadoras de este enfoque es la inclusión de un "Callback" personalizado para ajustar dinámicamente la tasa de aprendizaje durante el entrenamiento. Este ajuste se basa en la precisión del entrenamiento y la pérdida de validación. En resumen, si el modelo no mejora lo suficientemente rápido (según ciertos criterios preestablecidos), la tasa de aprendizaje se reduce, con la esperanza de mejorar la convergencia del modelo *Tasa de aprendizaje* 2023.

Este enfoque puede ser especialmente útil cuando nos enfrentamos a superficies de pérdida complejas con múltiples mínimos locales; al variar la tasa de aprendizaje, es más probable que el modelo salga de mínimos locales subóptimos y encuentre una solución mejor.

## Capítulo 3

# Detalles de Implementación y Experimentos



# Conclusiones

Los resultados obtenidos muestran una alta eficacia (79% aproximadamente) que puede estar sujeta a futuras mejoras del modelo y del algoritmo. En general, los modelos de detección de cáncer de piel pueden tener una precisión del 85% al 95% o superior, dependiendo de la complejidad del problema, la calidad de los datos y la selección del algoritmo utilizado. Sin embargo, el 78% es un porcentaje elevado para los algoritmos de aprendizaje automático, y con algunas mejoras en el modelo puede incrementarse. También se desprende de este resultado la intención de convertir este proyecto en un producto a gran escala para ser utilizado, inicialmente, por los profesionales sanitarios de atención primaria, como prueba complementaria de alta efectividad a la hora de derivar a un paciente con una lesión cutánea al área de oncología. Con la premisa de convertir los resultados obtenidos en un producto al servicio de la sociedad, el equipo investigador pretende seguir investigando y desarrollando una solución mejor.

# Recomendaciones

Recomendaciones

# Bibliografía

Adamax. (2023). (Vid. pág. 6).  
Aumentación de datos. (2023). (Vid. pág. 4).  
Capas densas. (2023). (Vid. pág. 5).  
Conjunto de datos HAM10000. (2023). (Vid. pág. 3).  
Dataframes de Pandas. (2023). (Vid. pág. 4).  
Dropout. (2023). (Vid. pág. 6).  
EfficientNetB1. (s.f.). (Vid. pág. 5).  
ImageDataGenerator. (2023). (Vid. pág. 4).  
One-hot encoding. (2023). (Vid. pág. 4).  
Regularización. (2023). (Vid. pág. 5).  
Tasa de aprendizaje. (2023). (Vid. pág. 6).